



Regressão e redes neurais rasas e profundas

Juvenal J. Duarte

Ementa

- Serão abordados nesta disciplina os seguintes tópicos:
 - Revisão de Cálculo Diferencial e Álgebra Linear
 - Introdução ao aprendizado de máquina
 - Regressão Linear
 - Definição de Função de Perda e Função de Custo (loss/cost)
 - Erro Quadrático Médio / Mean Squared Error (MSE)
 - Otimização por Gradiente Descendente (Batch Gradient Descent)
 - Regressão Logística e perceptron
 - Funções de ativação: Sigmoid e ReLU
 - Entropia Cruzada / Cross Entropy
 - Gradiente Descendente: Mini Batch e Estocástico
 - Multilayer Perceptron (MLP)
 - Algoritmo de feed-forward.
 - Backpropagation.




Revisão Cálculo diferencial

Juvenal J. Duarte

Cálculo diferencial

Derivada pela definição

$$\frac{dy}{dx}(x_i) = f'(x_i) = \lim_{h \rightarrow 0} \frac{f(x_i+h) - f(x_i)}{h}$$



Cálculo diferencial

Derivada de uma constante

$$\frac{d}{dx}(c) = 0$$

Derivada da potência

$$\frac{d}{dx}(x^n) = n \cdot x^{n-1}$$

Portanto:

$$\frac{d}{dx}(x) = 1$$

Soma / Subtração

$$\frac{d}{dx}(u \pm v) = \frac{du}{dx} \pm \frac{dv}{dx}$$

Produto por uma constante


$$\frac{d}{dx}(cu) = c \frac{du}{dx}$$

Derivada do produto

$$\frac{d}{dx}(uv) = u \frac{dv}{dx} + v \frac{du}{dx}$$


Cálculo diferencial: exemplos

Função constante




$$f(x) = 50$$
$$f'(x) = \frac{\partial y}{\partial x} = 0$$

Função linear



$$f(x) = 3x + 1$$
$$f'(x) = \frac{\partial y}{\partial x} = 3$$

Função quadrática



$$f(x) = x^2$$
$$f'(x) = \frac{\partial y}{\partial x} = 2x$$

Cálculo diferencial: exercícios

(1) $f(x) = 11$

(2) $f(x) = 4x + 20x + 2$

(3) $f(x) = 4x^3 + x + 1$

(4) Se a população mundial é dada pela função $f(x)$, qual interpretação pode ser dada à sua derivada?

Derivadas Parciais

Em funções de múltiplas variáveis, é possível estabelecer a derivada em relação a cada variável particular

Derivada em relação à "r"

$$V = \frac{r^2 h \pi}{3}$$
$$\frac{\partial V}{\partial r} = \frac{2rh\pi}{3}$$

Derivada em relação à "h"

$$\frac{\partial V}{\partial h} = \frac{r^2 \pi}{3}$$



Revisão Álgebra linear

Juvenal J. Duarte

Álgebra linear

Multiplicação por constante

$$3 \cdot [2 \ 4 \ 7] = [3 \cdot 2 \ 3 \cdot 4 \ 3 \cdot 7] = [6 \ 12 \ 21]$$

$$\frac{1}{2} \cdot \begin{bmatrix} 4 & 6 \\ 10 & 1 \end{bmatrix} = \begin{bmatrix} 4 \cdot 1/2 & 6 \cdot 1/2 \\ 10 \cdot 1/2 & 1 \cdot 1/2 \end{bmatrix} = \begin{bmatrix} 2 & 3 \\ 5 & \frac{1}{2} \end{bmatrix}$$

Álgebra linear

Multiplicação de matrizes

$[A] \times [B]$

$[A] = \begin{bmatrix} a_{11} & a_{12} & a_{13} \\ a_{21} & a_{22} & a_{23} \end{bmatrix}$

$[B] = \begin{bmatrix} b_{11} & b_{12} \\ b_{21} & b_{22} \\ b_{31} & b_{32} \end{bmatrix}$

$L_1C_1 = a_{11}b_{11} + a_{12}b_{21} + a_{13}b_{31}$

www.obaricentrodamente.com

Multiplicação exemplo:

$$A = \begin{bmatrix} 2 & 3 & 1 \\ -1 & 0 & 2 \end{bmatrix} \quad B = \begin{bmatrix} 1 & -2 \\ 0 & 5 \\ 4 & 1 \end{bmatrix}$$

$$A_{2 \times 3} \cdot B_{3 \times 2} = C_{2 \times 2}$$


$$C = \begin{bmatrix} 6 & 12 \\ 7 & 4 \end{bmatrix}$$



Introdução: Tipos de aprendizado

Juvenal J. Duarte

Aprendizado por indução



Aprendizado por indução

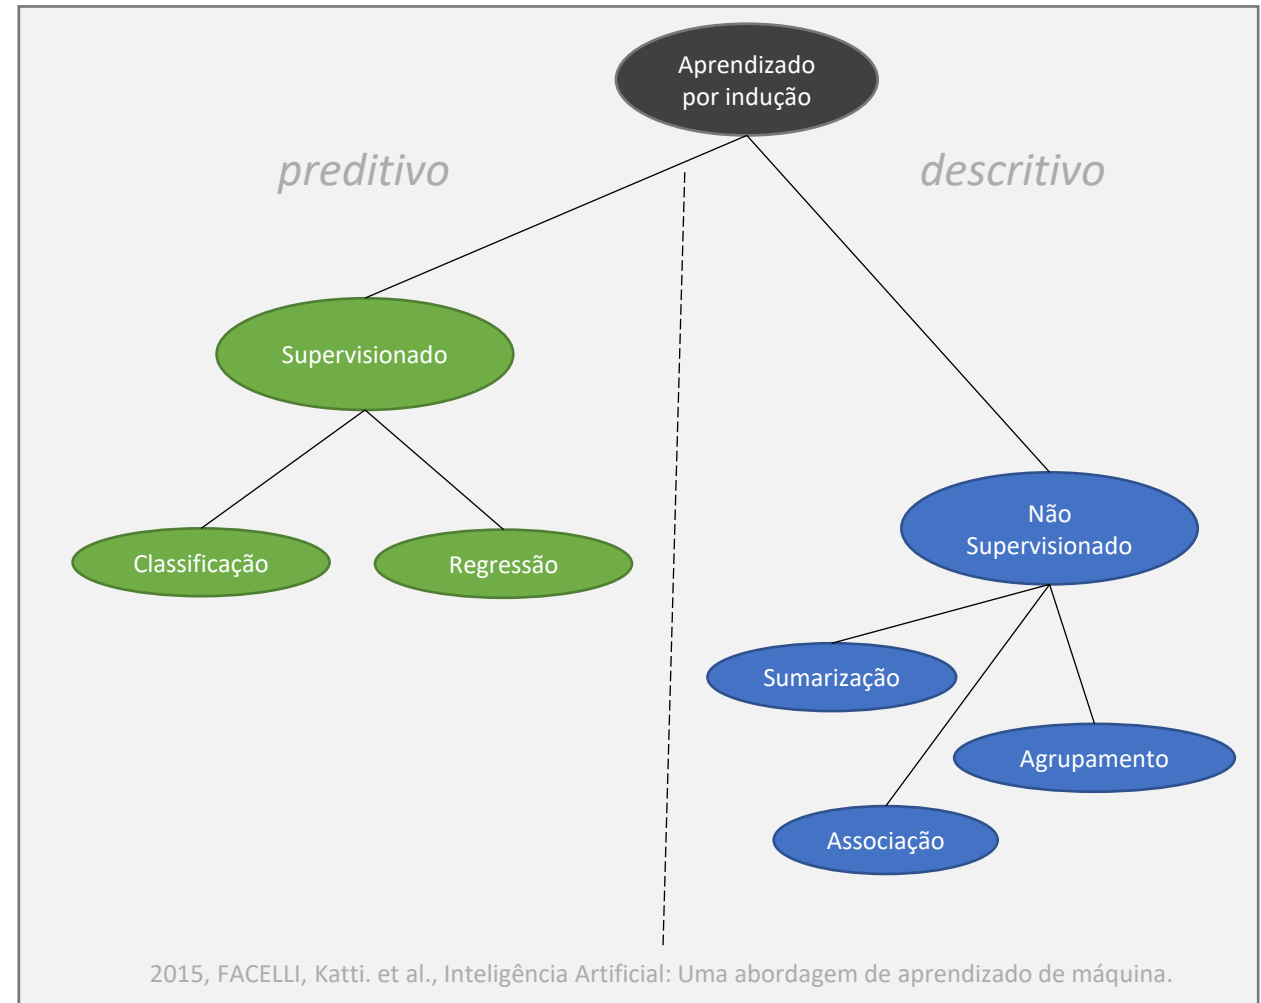
- Principais tarefas são:

- Predizer (Apr. Supervisionado):

- Diagnóstico de doenças.
 - Reconhecimento facial.
 - Predição de fraudes.
 - Predição de desistência (*churn*).
 - SAC: Qual será o volume de ligações?
 - Qual o preço justo de um imóvel?
 - Algum outro caso interessante?

- Descrever (Apr. não Supervisionado):

- Sistemas de recomendação.
 - Segmentação de clientes.
 - Agrupamento de documentos similares.
 - Algum outro exemplo?

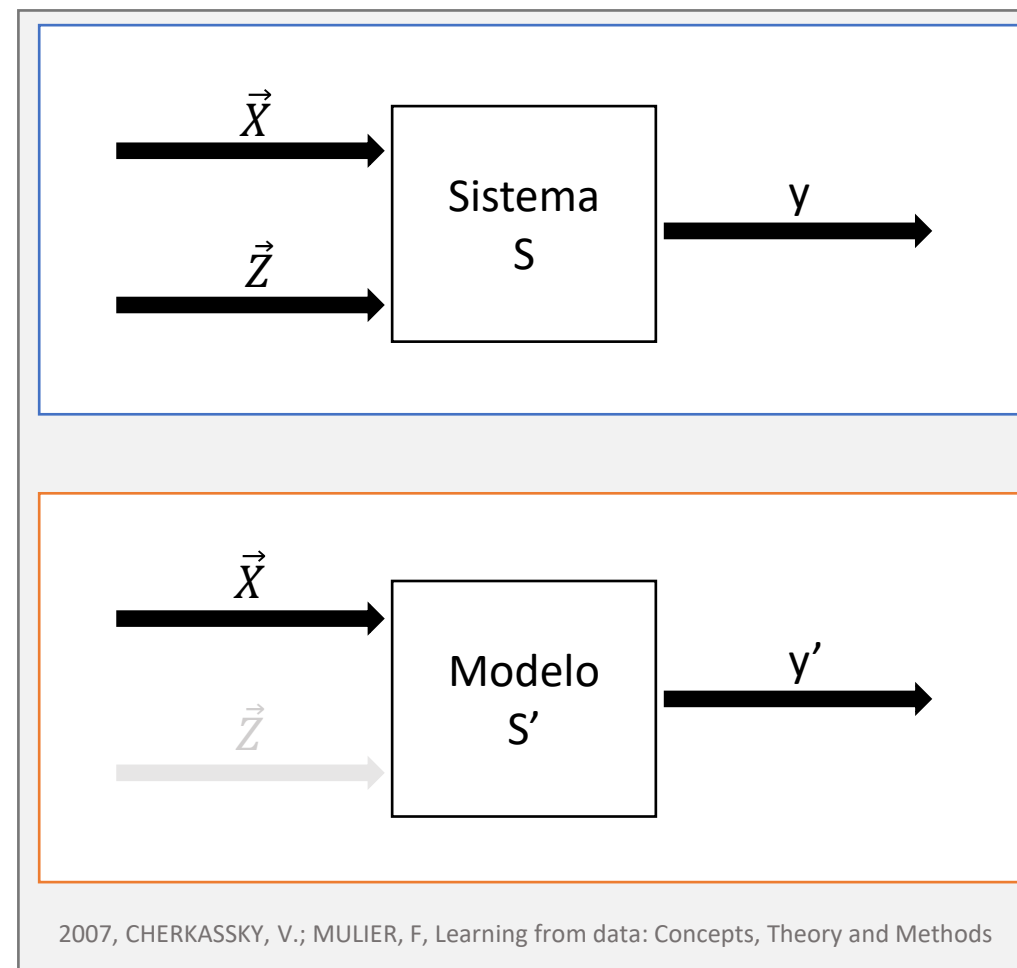


Aprendizado por indução

- Aprendizado supervisionado:
 - São fornecidos o conjunto de atributos independentes (\vec{X}) e o atributo alvo (y). A partir dos exemplos o algoritmo gera um modelo, por indução, capaz prever novas amostras por dedução.
- Aprendizado não supervisionado:
 - É fornecido apenas o conjunto de atributos (\vec{X}). Os algoritmos buscam padrões descritivos nos dados através da análise das características dos exemplos e suas relações.

Aprendizado supervisionado: Formalização

- Existe um sistema S , com entradas observadas \vec{X} e entradas não observadas \vec{Z} , que produz os resultados y baseado nos inputs.
- Existe um modelo S' , cuja função busca imitar o comportamento do Sistema S , mapeando o conjunto de entradas \vec{X} a uma saída y' .



Aprendizado supervisionado

- $S1 = 2, 4, 6, 8, 10 \dots ?$
- $S2 = 1, 4, 9, 16, 25 \dots ?$
- $S3 = 0, 1, 1, 2, 3, 5, 8, 13, 21 \dots ?$
- $S4 = \bullet, \square, \Delta, \bullet, \square, \Delta \dots ?$

Aprendizado supervisionado

- S1 = 2, 4, 6, 8, 10 ... ?
- S2 = 1, 4, 9, 16, 25 ... ?
- S3 = 0, 1, 1, 2, 3, 5, 8, 13, 21 ... ?
- S4 = ●, □, △, ●, □, △ ... ?

S1:

$$f(n) = 2n, \forall n > 0$$

S2:

$$f(n) = n^2, \forall n > 0$$


S3:

$$f(n) = \begin{cases} f(n-1) + f(n-2), \forall n > 1 \\ 1, n = 1 \\ 0, n = 0 \end{cases}$$

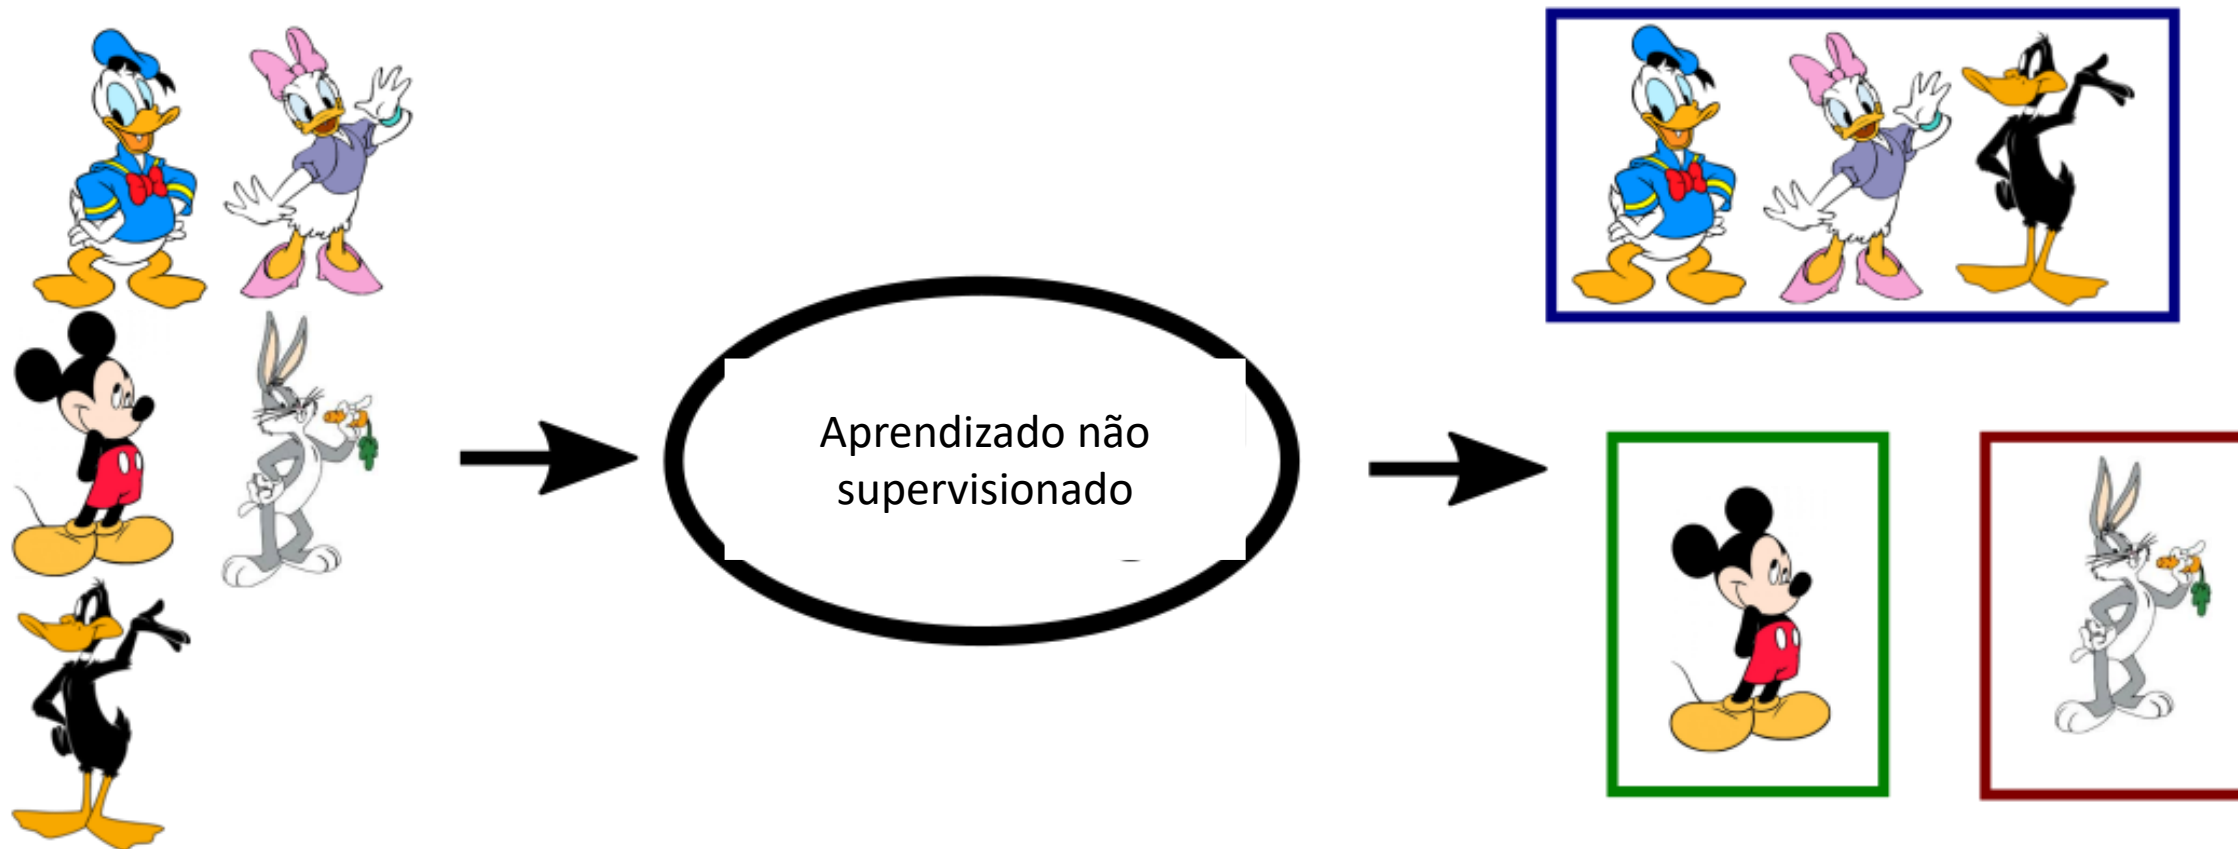
S4:

$$f(n) = \begin{cases} f(n-3), \forall n > 2 \\ \Delta, n = 2 \\ \square, n = 1 \\ \bullet, n = 0 \end{cases}$$

Aprendizado não supervisionado



Aprendizado não supervisionado



2018, Devin Soni, acessado em:
towardsdatascience.com/supervised-vs-unsupervised-learning-14f68e32ea8d







Regressão linear

Juvenal J. Duarte

Regressão linear

Investiga relações lineares entre variáveis. Qual das relações abaixo apresenta relação mais linear?



Wikipedia:
https://en.wikipedia.org/wiki/Linear_regression

Regressão linear univariada

O que é uma relação de dependência linear?

$$y = \beta x + \alpha$$

Notação alternativa:

$$y = mx + b$$

Regressão linear univariada

O que é uma relação de dependência linear?

The diagram shows the linear regression equation $y = \beta x + \alpha$. Four blue arrows point from text labels to the components of the equation: 'Variável dependente' points to y , 'Scale factor (curve slope)' points to β , 'Variável independente' points to x , and 'Bias' points to α . The coefficient β is colored red, and the bias α is colored green.

$$y = \beta x + \alpha$$

Variável dependente

Bias

Scale factor (curve slope)

Variável independente

Regressão linear multivariada

Como generalizar a formula para o caso de n atributos?

$$y = \beta_1 x_1 + \beta_2 x_2 + \beta_3 x_3 + \cdots + \beta_n x_n + \alpha$$



$$y = \alpha + \sum_{i=1}^n x_i \beta_i$$

Regressão linear multivariada

Cálculo vetorial

Quantidade de linhas / registros / amostras: m

Quantidade de colunas / atributos / características: n

Conjunto de entradas: $\vec{X}_{m,n} = \begin{bmatrix} x_{1,1} & \cdots & x_{1,n} \\ \vdots & \ddots & \vdots \\ x_{m,1} & \cdots & x_{m,n} \end{bmatrix}$

Conjunto de pesos: $\vec{B}_{n,1} = \begin{bmatrix} \beta_1 \\ \beta_2 \\ \beta_3 \\ \vdots \\ \beta_n \end{bmatrix}$

Bias: α

(1)

Predição (formula vetorial):

$$\hat{y}_{m,1} = \vec{X}_{m,n} \vec{B}_{n,1} + \alpha$$

Regressão linear: função de custo

Como estimar os parâmetros e saber se o modelo é bom o suficiente?


(2)

$$\text{loss}(i) = y_i - \hat{y}_i$$

Erro Quadrático Médio (MSE):

(3)

$$\text{cost} = J = \frac{1}{m} \sum_{i=1}^m \text{loss}(y_i, \hat{y}_i)^2$$






Regressão linear: Gradiente Descendente

Juvenal J. Duarte

Gradiente descendente

Parametros do modelo sao corrigidos iterativamente, com ajuste dado pela derivada da função de custo.



Regressão linear: gradiente descendente

$$(3) \quad J = \frac{1}{m} \sum_{i=1}^m \text{loss}(y_i, \hat{y}_i)^2$$



$$\frac{\partial J}{\partial \beta} = \frac{1}{m} \sum_{i=1}^m -2\vec{x}_i(y_i - (\vec{x}_i\beta + \alpha))$$



$$\frac{\partial J}{\partial \alpha} = \frac{1}{m} \sum_{i=1}^m -2(y_i - (\vec{x}_i\beta + \alpha))$$

Regressão linear: gradiente descendente

$$(3) \quad J = \frac{1}{m} \sum_{i=1}^m \text{loss}(y_i, \hat{y}_i)^2$$



$$(4) \quad \frac{\partial J}{\partial \beta} = -\frac{2}{m} \times \text{transp}(\vec{X}_{m,n}) \times [y_{m,1} - (\vec{X}_{m,n} \times \vec{B}_{n,1} + \alpha)]$$



$$(5) \quad \frac{\partial J}{\partial \alpha} = -\frac{2}{m} \times \sum (y_{m,1} - (\vec{X}_{m,n} \times \vec{B}_{n,1} + \alpha))$$

Hiper-Parametros

Learning Rate = Alpha:

Define a velocidade do aprendizado. Quando baixa, exige mais iteracoes ate a solucao otima, quando alta dificulta a convergencia do algoritmo.

Epochs:

Define quantas iteracoes de ajustes nos coeficientes serao executadas.

Ajuste dos pesos / coeficientes

(6)

$$\vec{B}_{n,1} = \vec{B}_{n,1} - \text{alpha} \times \frac{\partial J}{\partial \beta}$$

(7)

$$\alpha = \alpha - \text{alpha} \times \frac{\partial J}{\partial \alpha}$$