



Regressão e redes neurais rasas

Juvenal J. Duarte



Regressão linear: Revisão

Juvenal J. Duarte

Regressão linear multivariada

Quantidade de linhas / registros / amostras: m

Quantidade de colunas / atributos / características: n

Conjunto de entradas: $\vec{X}_{m,n} = \begin{bmatrix} x_{1,1} & \cdots & x_{1,n} \\ \vdots & \ddots & \vdots \\ x_{m,1} & \cdots & x_{m,n} \end{bmatrix}$

Conjunto de pesos: $\vec{B}_{n,1} = \begin{bmatrix} \beta_1 \\ \beta_2 \\ \beta_3 \\ \vdots \\ \beta_n \end{bmatrix}$

Bias: α

(1)

Predição (formula vetorial):


$$\hat{y}_{m,1} = \vec{X}_{m,n} \vec{B}_{n,1} + \alpha$$

Regressão linear multivariada

Problema mapeado como regressão:

Entrada: Vetor de números reais.

Saída: Número real.



Regressão linear multivariada

1. Calcular as previsões para cada um dos exemplos no conjunto de teste, pela função \hat{y} .
2. Calcular cada uma das perdas individuais pela função de perda:
$$\text{loss}(y, \hat{y}) = y - \hat{y}$$
3. Calcular o custo do modelo dados os pesos escolhidos:
$$J(B, \alpha) = \frac{1}{m} \sum_{i=1}^m \text{loss}(y, \hat{y})^2$$
4. Calcular os gradientes em relação aos pesos $\frac{\partial J}{\partial B}$ e ao bias $\frac{\partial J}{\partial \alpha}$.
5. Atualizar os pesos e o bias de acordo com o gradiente e a taxa de aprendizado.
6. Repetir o processo iterativamente até que as iterações se excedam.




Regressão Logística Binária

Juvenal J. Duarte


Regressão / Classificação:

Regressor: $f: X \rightarrow y \mid y \in \mathbb{R}$




Funções de decisão: $f: X \rightarrow y \mid y \in \{c_1, c_2, \dots, c_n\}$

Binária




Multi-classe




Função sigmoid

É uma função em formato de 'S', com domínio (entradas) em números reais e imagem (saídas) limitadas a um intervalo, normalmente $[0,1]$ ou $[-1,1]$.

FUNÇÃO LOGÍSTICA



OUTRAS FUNÇÕES SIGMOID



Função Logística

É uma função sigmoidal cujos valores de saída variam no intervalo $[0, L]$, sendo o valor mais comum $[0,1]$.

$$f(x) = \frac{L}{1 + e^{-kx}}$$


Onde:

L = valor máximo da função

e = número Euler, base do logarítmo natural

k = taxa de crescimento


x = entrada



Função Logística


$$\lim_{n \rightarrow \infty} e^{-n} = ?$$

$$\lim_{n \rightarrow -\infty} e^{-n} = ?$$



$$\lim_{n \rightarrow \infty} \frac{1}{1 + e^{-n}} = ?$$


$$\lim_{n \rightarrow -\infty} \frac{1}{1 + e^{-n}} = ?$$



Função Logística


$$\lim_{n \rightarrow \infty} e^{-n} = 0$$

$$\lim_{n \rightarrow -\infty} e^{-n} = \infty$$



$$\lim_{n \rightarrow \infty} \frac{1}{1 + e^{-n}} = ?$$


$$\lim_{n \rightarrow -\infty} \frac{1}{1 + e^{-n}} = ?$$



Função Logística


$$\lim_{n \rightarrow \infty} e^{-n} = 0$$

$$\lim_{n \rightarrow -\infty} e^{-n} = \infty$$



$$\lim_{n \rightarrow \infty} \frac{1}{1 + e^{-n}} = 1$$

$$\lim_{n \rightarrow -\infty} \frac{1}{1 + e^{-n}} = 0$$



Função Logística

$$\lim_{n \rightarrow \infty} e^{-n} = 0$$


$$\lim_{n \rightarrow -\infty} e^{-n} = \infty$$

Conclusão:

A função se aproxima de 0 pela esquerda, mas nunca chega. A função se aproxima de 1 pela direita, mas também nunca chega. Temos duas assíntotas horizontais.

$$\lim_{n \rightarrow \infty} \frac{1}{1 + e^{-n}} = 1$$

$$\lim_{n \rightarrow -\infty} \frac{1}{1 + e^{-n}} = 0$$



Regressão logística multivariada

Quantidade de linhas / registros / amostras: m

Quantidade de colunas / atributos / características: n

Conjunto de entradas: $\vec{X}_{m,n} = \begin{bmatrix} x_{1,1} & \cdots & x_{1,n} \\ \vdots & \ddots & \vdots \\ x_{m,1} & \cdots & x_{m,n} \end{bmatrix}$

Conjunto de pesos: $\vec{B}_{n,1} = \begin{bmatrix} \beta_1 \\ \beta_2 \\ \beta_3 \\ \vdots \\ \beta_n \end{bmatrix}$

Bias: α

(1)

Predição (formula vetorial):

$$\hat{y}_{m,1} = \frac{1}{1 + e^{-(\vec{X}_{m,n} \vec{B}_{n,1} + \alpha)}}$$

Regressão Logística: Função de custo

(2)

$$loss(i) = y_i - \hat{y}_i$$

(3) Erro Quadrático Médio

$$cost(\beta, \alpha) = J = \frac{1}{m} \sum_{i=1}^m loss(y_i, \hat{y}_i)^2$$


Regressão Logística: Função de custo

(2)

$$\text{loss}(i) = y_i - \hat{y}_i$$

(3) Erro Quadrático Médio

$$\text{cost}(\beta, \alpha) = J = \frac{1}{m} \sum_{i=1}^m \text{loss}(y_i, \hat{y}_i)^2$$



(3) Entropia Cruzada

$$\text{cost}(\beta, \alpha) = J = \frac{1}{m} \sum_{i=1}^m -[y_i \log(\hat{y}_i) + (1 - y_i) \log(1 - \hat{y}_i)]$$

Regressão Logística: Função de custo

(3) Entropia Cruzada


$$cost(\beta, \alpha) = J = \frac{1}{m} \sum_{i=1}^m -[y_i \log(\hat{y}_i) + (1 - y_i) \log(1 - \hat{y}_i)]$$



Regressão Logística: Função de custo


(3) Entropia Cruzada

$$cost(\beta, \alpha) = J = \frac{1}{m} \sum_{i=1}^m -[y_i \log(\hat{y}_i) + (1 - y_i) \log(1 - \hat{y}_i)]$$





$$\begin{cases} -\log(\hat{y}). & , se y = 1 \\ -\log(1 - \hat{y}) & , se y = 0 \end{cases}$$

Funções Convexas





Funções Convexas

Uma função é chamada convexa se o segmento de reta entre quaisquer dois pontos no gráfico se encontra acima ou sobre o gráfico.





Funções Convexas

Uma função é chamada convexa se o segmento de reta entre quaisquer dois pontos no gráfico se encontra acima ou sobre o gráfico.




Funções Convexas

Uma função é chamada convexa se o segmento de reta entre quaisquer dois pontos no gráfico se encontra acima ou sobre o gráfico.



Funções Convexas


Uma função é chamada convexa se o segmento de reta entre quaisquer dois pontos no gráfico se encontra acima ou sobre o gráfico.



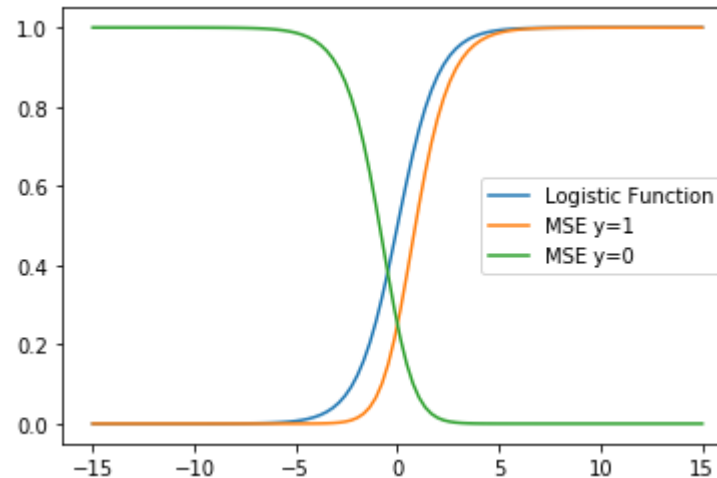
Convexidade de Funções de custo

Erros Quadráticos Médios (MSE) Vs Entropia Cruzada

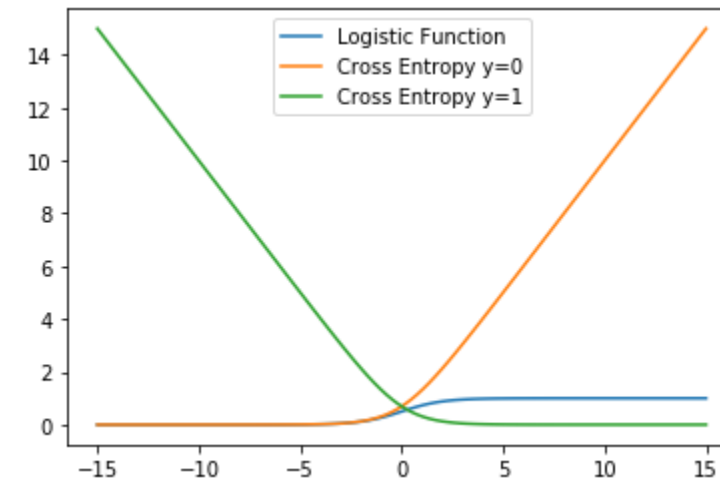
Reg. Linear & MSE



Reg. Logística & MSE




Reg. Logística & Entropia Cruzada



Convexidade de Funções de custo


Erros Quadráticos Médios (MSE) Vs Entropia Cruzada

Reg. Linear & MSE



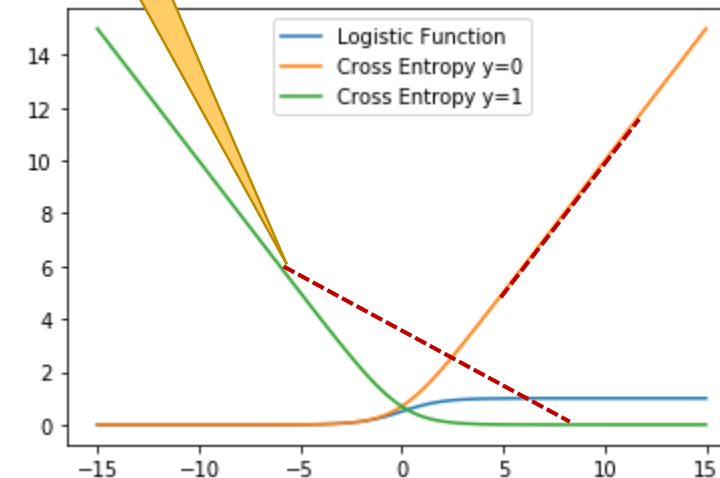
Não é
convexa!

Reg. Logística & MSE



É
convexa!

Reg. Logística & Entropia Cruzada



Sigmoides e Funções de custo


Exercício
Prático




Regressão logística: gradiente descendente

(3) Entropia Cruzada

$$cost(\beta, \alpha) = J = \frac{1}{m} \sum_{i=1}^m -[y_i \log(\hat{y}_i) + (1 - y_i) \log(1 - \hat{y}_i)]$$


$$^{(4)} \quad \frac{\partial J}{\partial \beta} = \frac{1}{m} \times \text{transp}(\vec{X}_{m,n}) \times [y_{m,1} - \hat{y}_{m,1}]$$


$$^{(5)} \quad \frac{\partial J}{\partial \alpha} = \frac{1}{m} \times \sum [y_{m,1} - \hat{y}_{m,1}]$$

Hiper-Parametros

Learning Rate = Alpha:

Define a velocidade do aprendizado. Quando baixa, exige mais iteracoes ate a solucao otima, quando alta dificulta a convergencia do algoritmo.

Epochs:

Define quantas iteracoes de ajustes nos coeficientes serao executadas.

Ajuste dos pesos / coeficientes


(6)

$$\vec{B}_{n,1} = \vec{B}_{n,1} - \text{alpha} \times \frac{\partial J}{\partial \beta}$$

(7)

$$\alpha = \alpha - \text{alpha} \times \frac{\partial J}{\partial \alpha}$$

Threshold de decisão






Regressão Logística Multiclasse

Juvenal J. Duarte

Abordagem para o problema

1. Para cada classe do problema, construa um classificador binário para recuperar a pontuação de cada registro em relação a esta classe.
2. Atribua a classe cuja ativação seja mais alta.

Abordagem para o problema: exemplo





Gradiente Descendente:

Batch, Mini Batch e Estocástico

Juvenal J. Duarte

Comparativo de abordagens

- **Batch:** A cada iteração/ época todos os registros de treino são avaliados antes de calcular o gradiente.
- **Mini Batch:** São divididos subgrupos de registros para avaliação do gradiente, com mais de um atualização por época.
- **Estocástico:** A cada época o gradiente é atualizado uma vez por registro.


Batch

Calcula o gradiente uma vez só a cada iteração, com o valor médio entre todos os registros.

$$\vec{X}_{m,n} = \begin{bmatrix} x_{1,1} & \cdots & x_{1,n} \\ \vdots & \ddots & \vdots \\ x_{m,1} & \cdots & x_{m,n} \end{bmatrix}$$



m




Minibatches

Minibatches

Divide os dados em porções de tamanho fixo, atualiza os pesos com o gradiente calculado a partir desses exemplos.

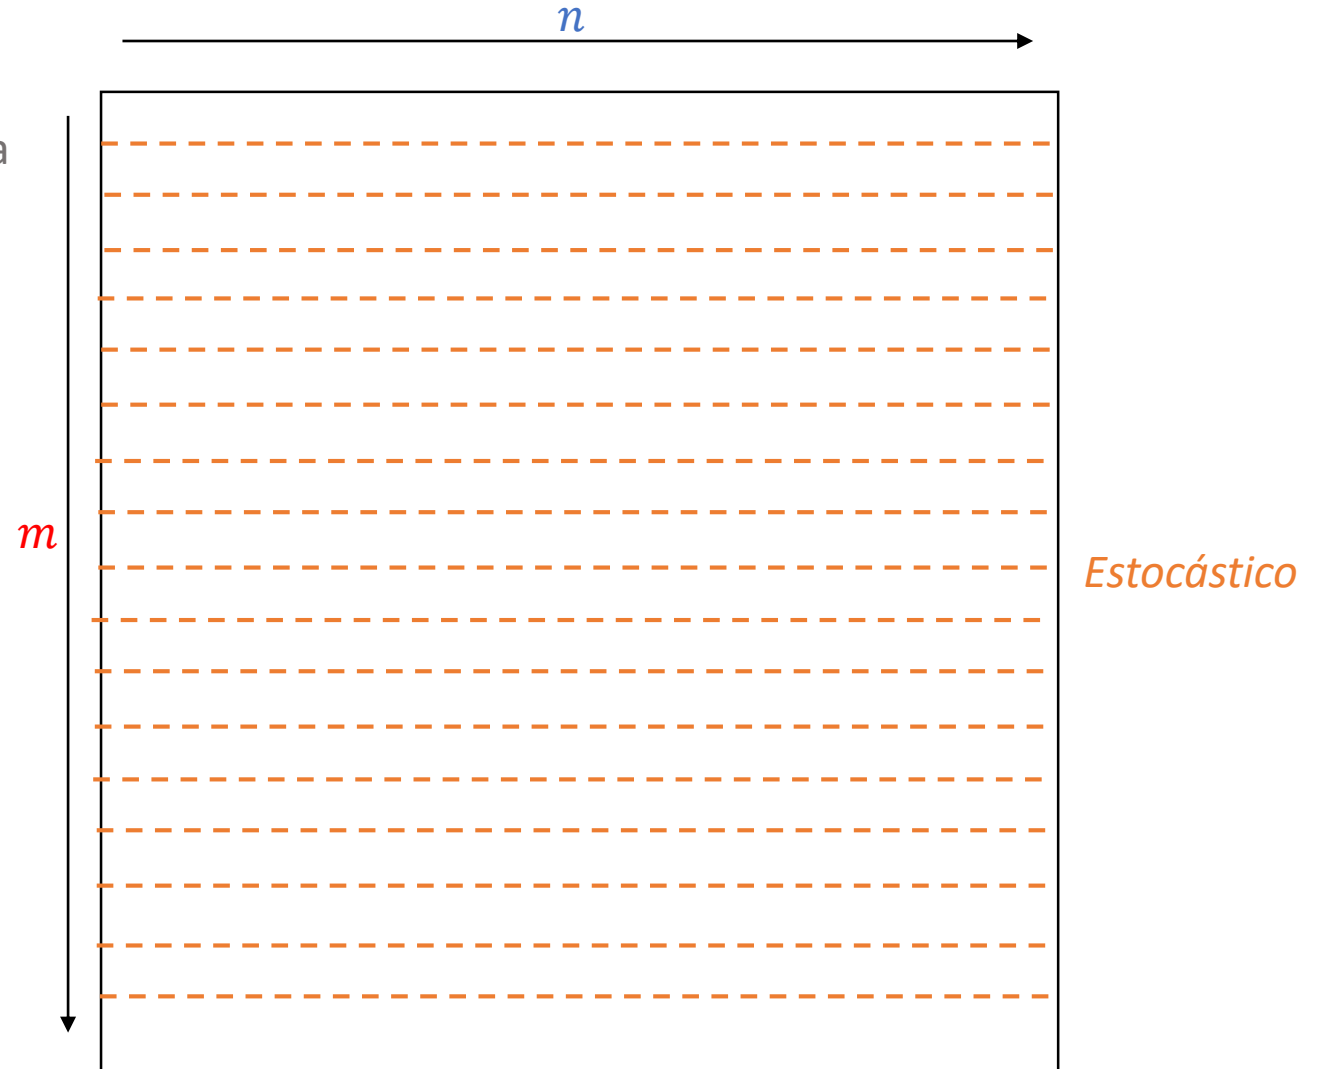
$$\vec{X}_{m,n} = \begin{bmatrix} x_{1,1} & \cdots & x_{1,n} \\ \vdots & \ddots & \vdots \\ x_{m,1} & \cdots & x_{m,n} \end{bmatrix}$$



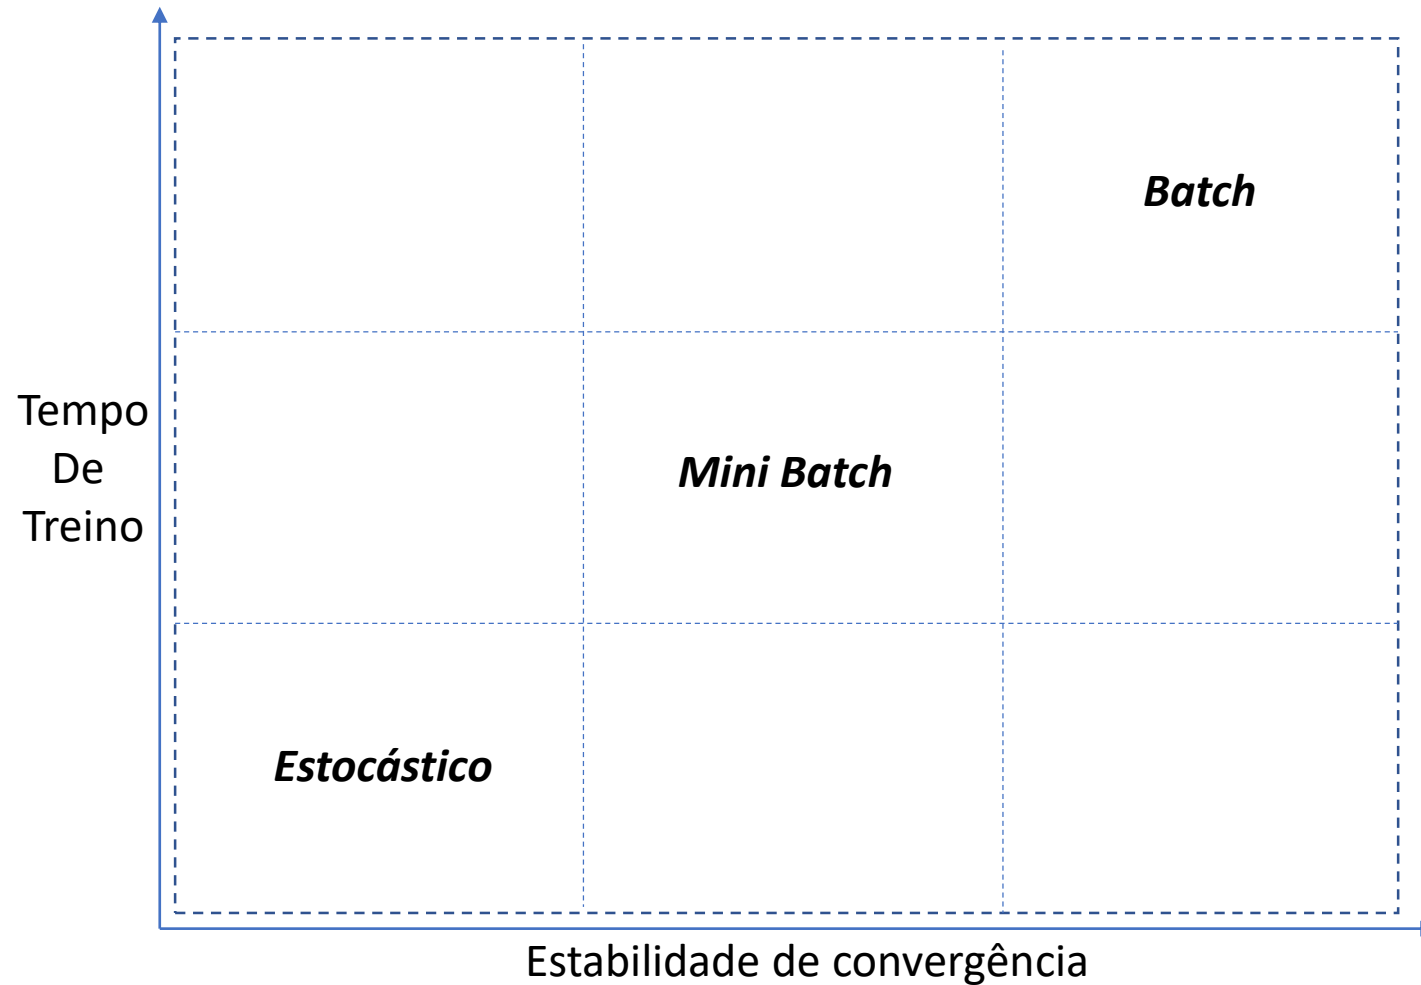
Estocástico

Calcula o gradiente e atualiza os pesos a para cada Registro.

$$\vec{X}_{m,n} = \begin{bmatrix} x_{1,1} & \cdots & x_{1,n} \\ \vdots & \ddots & \vdots \\ x_{m,1} & \cdots & x_{m,n} \end{bmatrix}$$




Comparativo de abordagens




Comparativo de abordagens


Estocástico



Mini Batch



Batch







Multilayer Perceptron (MLP): Introdução

Juvenal J. Duarte

O perceptron



O Multilayer Perceptron



O Multilayer Perceptron: definições

Quais as variáveis que temos por neurônio?

$\vec{A}^{[i-1]}$: entradas vindas dos neurônios da camada anterior. Quando $i = 0$, representa os valores de cada um dos atributos de entrada.

$a_k^{[i]}$: saída do neurônio k na camada i .

$\vec{W}_k^{[i]}$: vetor de pesos para cada uma das saídas camada $i - 1$, usado no neurônio k .

$b_k^{[i]}$: bias usado no neurônio k , camada i .

O Multilayer Perceptron: definições

Quais as variáveis que temos por neurônio?

$$\vec{A}^{[i-1]}: \vec{X}$$

$$a_k^{[i]}: \hat{y}$$

$$\vec{W}_k^{[i]}: \vec{\beta}$$

$$b_k^{[i]}: \alpha$$

O Multilayer Perceptron

